UNIVERSIDAD DE LA SALLE

Facultad de Ingeniería · Ingeniería de Software

Actividad 6. Mini-proyecto de Machine Learning

Predicción de reincidencia penal con Regresión Logística: desempeño, matriz de confusión y análisis ético con el dataset COMPAS

Estudiante:

Ximena Sánchez Martínez

Asignatura:

Teoría de la Computación II

Repositorio (rama develop):

https://github.com/SanMarx27/proyectoFinal_reincidenciaJusta/tree/develop

Bogotá D.C., noviembre de 2026

1. Modelo seleccionado y propósito

Problema. Varios sistemas judiciales usan algoritmos para estimar el riesgo de que una persona acusada vuelva a delinquir. El más conocido es COMPAS, empleado en Estados Unidos para decisiones de libertad provisional y fianza. El propósito de este mini-proyecto es construir un modelo sencillo que estime la probabilidad de reincidencia en los dos años siguientes, medir qué tan bien funciona y, sobre todo, analizar a quién perjudican sus errores.

Modelo elegido: Regresión Logística. Es un modelo de clasificación binaria que combina las variables de forma lineal y transforma el resultado en una probabilidad entre 0 y 1 mediante la función sigmoide. Se eligió por tres razones:

- **Transparencia:** cada variable tiene un coeficiente que se puede leer y explicar. En un contexto judicial, una persona tiene derecho a saber por qué se le asignó un riesgo.
- **Probabilidades:** entrega un grado de riesgo, no solo un «sí» o un «no».
- **Desempeño:** se comparó con un Árbol de Decisión y con KNN usando validación cruzada. Obtuvo el mejor AUC (0,726) y un F1 prácticamente igual al de los demás (diferencias de 0,01, menores que la variación entre particiones).

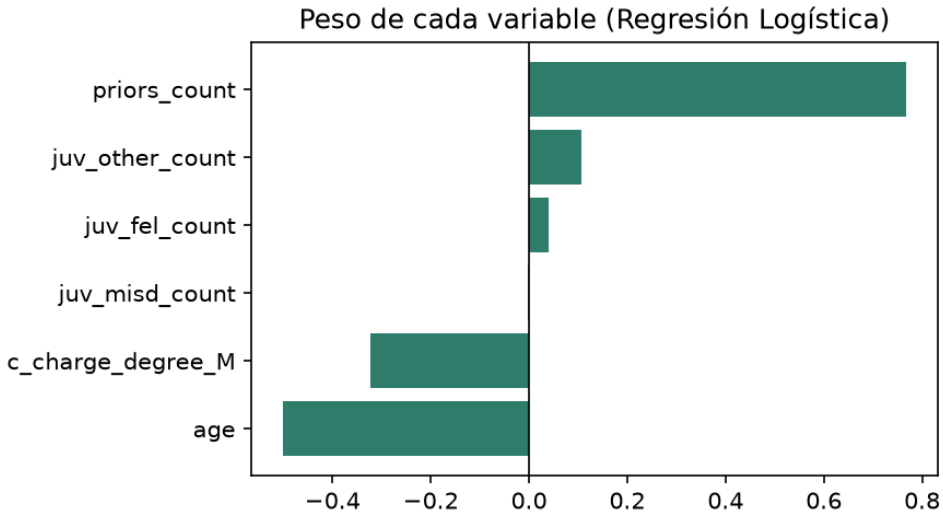


Figura 1. Coeficientes del modelo. Los antecedentes aumentan el riesgo; la edad lo reduce.

2. Descripción del dataset

Se usó el dataset público **COMPAS** publicado por ProPublica (2016): personas evaluadas en el condado de Broward (Florida) entre 2013 y 2014. De 7.214 registros quedaron **6.172** tras aplicar los mismos filtros de ProPublica (arresto a menos de 30 días de la evaluación, caso con desenlace conocido y delitos ordinarios).

Objetivo del modelo: predecir *two_year_recid* (1 = la persona volvió a ser acusada en dos años). La tasa de reincidencia es de 45,5 %, así que las clases están razonablemente equilibradas.

Variable	Tipo	Uso	Descripción
age	Numérica	Entrada	Edad en años
priors_count	Numérica	Entrada	Número de antecedentes como adulto
juv_fel_count	Numérica	Entrada	Delitos graves juveniles
juv_misd_count	Numérica	Entrada	Delitos menores juveniles
juv_other_count	Numérica	Entrada	Otros antecedentes juveniles
c_charge_degree	Categórica	Entrada	F = delito grave (felony); M = menor (misdemeanor)
race, sex	Categóricas	Solo auditoría	No entran al modelo; se usan para medir la equidad
decile_score	Numérica	Comparación	Puntaje COMPAS (1-10)
two_year_recid	Binaria	Objetivo	1 = reincidió en dos años

Muestra de los datos limpios (sin nombres, fechas ni números de caso):

edad	antec.	juv_fel	juv_misd	juv_otros	grado	raza	sexo	decil	reincide
69	0	0	0	0	F	Other	Male	1	0
34	0	0	0	0	F	African-American	Male	3	1
24	4	0	0	1	F	African-American	Male	4	1
44	0	0	0	0	M	Other	Male	1	0
41	14	0	0	0	F	Caucasian	Male	6	1
43	3	0	0	0	F	Other	Male	4	0

Composición: African-American 3.175, Caucasian 2.103, Hispanic 509, Other 343, Asian 31, Native American 11; Male 4.997, Female 1.175.

Separación: 80 % entrenamiento (4.937) y 20 % prueba (1.235), estratificada y con semilla fija. Los modelos se compararon con validación cruzada de 5 particiones dentro del entrenamiento; la prueba se usó una sola vez.

3. Métricas de evaluación

Resultados en el conjunto de prueba (1.235 personas). El modelo de referencia predice siempre la clase más frecuente («no reincide») y sirve para saber si el modelo aporta algo. La fila de COMPAS usa el puntaje real de la herramienta (decil ≥ 5 = riesgo medio o alto).

Modelo	Accuracy	Precision	Recall	F1	AUC
Referencia (clase mayoritaria)	0,545	0,000	0,000	0,000	0,500
Regresión Logística	0,685	0,719	0,505	0,594	0,731
Árbol de Decisión	0,687	0,684	0,582	0,629	0,728
KNN (k=15)	0,675	0,662	0,585	0,621	0,707
COMPAS (decil ≥ 5)	0,663	0,637	0,605	0,620	0,716

Interpretación de cada métrica (Regresión Logística)

- **Accuracy = 0,685:** acierta en 69 de cada 100 personas, frente a 55 de la referencia. Aporta, pero falla en casi un tercio de los casos.
- **Precision = 0,719:** de cada 100 personas marcadas como de alto riesgo, 72 sí reincidieron y 28 no. Esas 28 recibirían un trato más duro sin motivo.
- **Recall = 0,505:** solo detecta a la mitad de quienes reincidieron.
- **F1 = 0,594:** resume precision y recall; queda bajo por el recall.
- **AUC = 0,731:** el 73 % de las veces le da más riesgo a quien sí reincide que a quien no. Es el mismo nivel que COMPAS (0,716), con solo seis variables públicas.

Implicación: el modelo es mejor que adivinar y comparable a una herramienta comercial, pero su techo es bajo. Con estas variables no se puede predecir el comportamiento futuro de una persona con mucha seguridad. Dressel y Farid (2018) llegaron a la misma conclusión: personas sin formación jurídica acertaban tanto como COMPAS.

4. Matriz de confusión

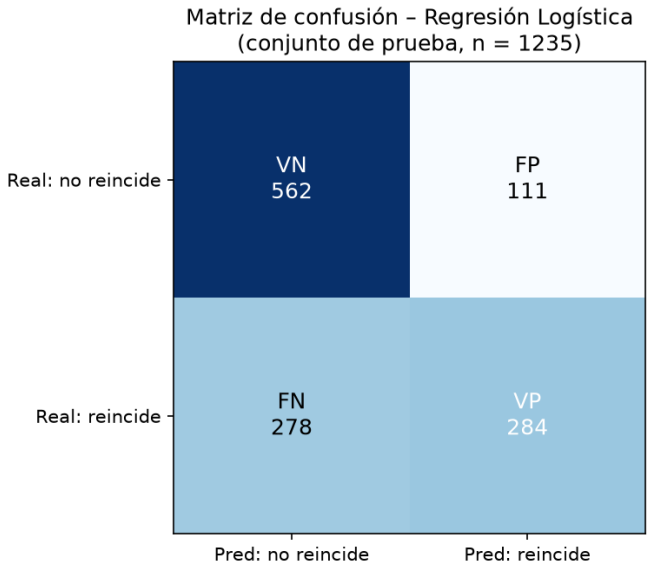


Figura 2. Matriz de confusión de la Regresión Logística en el conjunto de prueba.

- **Verdaderos positivos (VP = 284):** personas que reincidieron y el modelo marcó como de alto riesgo. Acierto.
- **Verdaderos negativos (VN = 562):** personas que no reincidieron y el modelo marcó como de bajo riesgo. Acierto.
- **Falsos positivos (FP = 111):** personas que no reincidieron, pero el modelo las marcó como de alto riesgo. Es el error más grave desde los derechos: puede llevar a negar la libertad a alguien que no lo merecía.
- **Falsos negativos (FN = 278):** personas que sí reincidieron, pero el modelo las dejó como de bajo riesgo. Afecta la seguridad de posibles víctimas.

El modelo es «prudente»: comete pocos falsos positivos (111) a cambio de muchos falsos negativos (278). Mover el umbral de 0,5 cambia ese equilibrio, y esa es una decisión de política, no técnica.

5. Análisis ético

5.1 Sesgos del dataset y del modelo

La etiqueta no mide «volver a delinquir» sino «volver a ser acusado». Si la policía patrulla más ciertos barrios, las personas de esos barrios acumulan más arrestos y más antecedentes. El modelo no usa la raza, pero sí los antecedentes, que funcionan como **variable sustituta (proxy)** de esos patrones de vigilancia desiguales.

Grupo (prueba)	n	Reincidencia real	Marcados alto riesgo	FPR modelo	FNR modelo	FPR COMPAS
Afroamericano	641	52,6 %	44,0 %	0,237	0,377	0,401

Grupo (prueba)	n	Reincidencia real	Marcados alto riesgo	FPR modelo	FNR modelo	FPR COMPAS
Caucásico	427	37,7 %	19,2 %	0,113	0,677	0,207
Hombres	1002	47,6 %	34,9 %	0,192	0,478	—
Mujeres	233	36,5 %	19,3 %	0,068	0,588	—

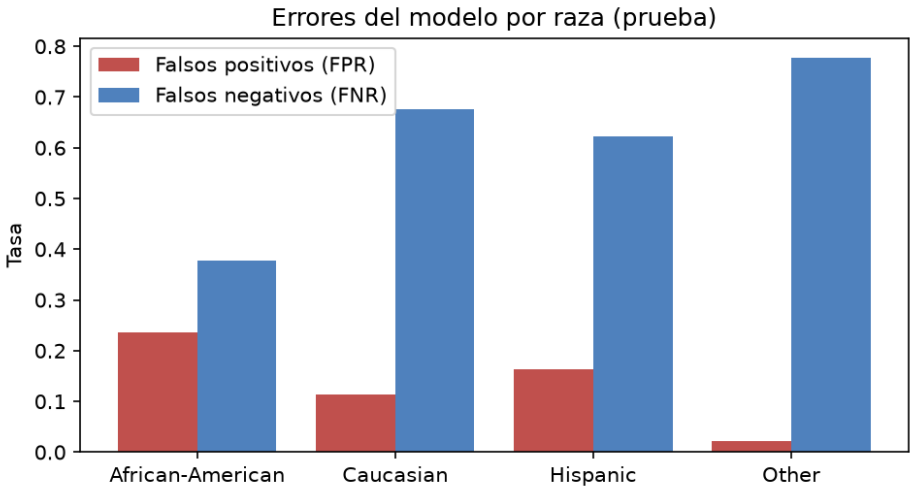


Figura 3. Tasas de error por raza en el conjunto de prueba.

Una persona afroamericana que **no** reincide tiene el doble de probabilidad de ser marcada como de alto riesgo que una caucásica (FPR 0,237 frente a 0,113). A las personas caucásicas el modelo les deja pasar más reincidencias (FNR 0,677). COMPAS tiene la misma brecha, más grande (0,401 frente a 0,207). Nuestro modelo la reduce, pero no la elimina: brecha de 0,124, por encima del máximo tolerado de 0,10.

5.2 Equidad

Chouldechova (2017) y Kleinberg et al. (2017) demostraron que, cuando dos grupos tienen tasas de reincidencia distintas, es matemáticamente imposible que un modelo sea a la vez igual de preciso para ambos y tenga las mismas tasas de error. Siempre hay que escoger qué tipo de justicia se prioriza. Esa elección no le corresponde al ingeniero: es una decisión jurídica y social que debe ser explícita.

5.3 Privacidad y uso responsable de los datos

- El CSV original contiene nombres, fechas de nacimiento y números de caso de personas reales. No se sube al repositorio; el código conserva solo diez columnas necesarias (minimización de datos).
- Aunque los datos son públicos, siguen siendo datos sensibles sobre antecedentes penales. En Colombia, la Ley 1581 de 2012 los trata como datos sensibles que requieren protección reforzada.
- El modelo no se despliega ni se expone como servicio, para que no se pueda usar con personas reales.

5.4 Impacto social

Un falso positivo puede significar meses de detención preventiva, pérdida del empleo y ruptura familiar. Si esos errores se concentran en un grupo, el algoritmo refuerza una desigualdad que ya existía, y lo hace con apariencia de objetividad. Además, los nuevos arrestos alimentan los datos del siguiente modelo: es un ciclo que se retroalimenta.

5.5 Justicia y transparencia en la toma de decisiones

COMPAS es un software propietario: los acusados no pueden conocer cómo se calcula su puntaje. Este proyecto muestra que un modelo abierto de seis variables obtiene el mismo desempeño. Por eso la opacidad no se justifica técnicamente. Cualquier herramienta de este tipo debería ser auditable, explicable a la persona afectada y usarse solo como apoyo, nunca como reemplazo, del juicio humano, con posibilidad de controvertir el resultado (debido proceso).

6. Conclusiones técnicas

- La Regresión Logística supera claramente a la referencia (F1 0,594 frente a 0) y cumple los criterios de desempeño: F1 ≥ 0,550 y AUC ≥ 0,700.
- Su capacidad de discriminación (AUC 0,731) es igual a la de COMPAS, con un modelo más simple y transparente.
- Los cuatro modelos quedaron muy cerca entre sí. El límite no está en el algoritmo, sino en la poca información que contienen las variables.
- El recall es bajo (0,505): el modelo deja pasar a la mitad de quienes reinciden.
- No hubo sobreajuste: las métricas de validación cruzada y de prueba difieren en menos de 0,02.
- **No cumple el criterio de equidad** (brecha de FPR 0,124 > 0,10). Veredicto: es aceptable como ejercicio académico, pero **no es apto para decisiones sobre personas reales**.

7. Recomendaciones para mejorar

- **Ajustar umbrales por grupo** o usar técnicas de mitigación (reponderación, post-procesamiento con *equalized odds*, por ejemplo con la librería Fairlearn) y medir cuánto desempeño se sacrifica.
- **Mejorar la etiqueta:** usar condenas en lugar de nuevas acusaciones, para reducir el efecto de la vigilancia policial desigual.
- **Más y mejores variables:** factores protectores (empleo, estudio, red de apoyo) en vez de solo antecedentes.
- **Calibrar el umbral** con validación cruzada según el costo real de cada error (FP frente a FN), definido con expertos jurídicos.
- **Validar con otros datos:** otras jurisdicciones y años, incluido el contexto colombiano.
- **Gobernanza:** auditorías externas periódicas, explicación individual de cada puntaje y supervisión humana obligatoria.

Referencias

Angwin, J., Larson, J., Mattu, S. y Kirchner, L. (2016). *Machine bias*. ProPublica. https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing

Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, *5*(2), 153-163. https://doi.org/10.1089/big.2016.0047

Congreso de Colombia. (2012). *Ley 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales*.

Dressel, J. y Farid, H. (2018). The accuracy, fairness, and limits of predicting recidivism. *Science Advances*, *4*(1). https://doi.org/10.1126/sciadv.aao5580

Kleinberg, J., Mullainathan, S. y Raghavan, M. (2017). Inherent trade-offs in the fair determination of risk scores. *ITCS 2017*. https://arxiv.org/abs/1609.05807

Larson, J., Mattu, S., Kirchner, L. y Angwin, J. (2016). *How we analyzed the COMPAS recidivism algorithm*. ProPublica. https://github.com/propublica/compas-analysis

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.